Laporan Training dan Evaluasi Model Image Classification

1. Introduction

Project ini bertujuan untuk membangun model deep learning yang dapat melakukan klasifikasi gambar sampah ke dalam beberapa kategori. Dataset yang digunakan merupakan dataset image classification yang berisi enam kelas, yaitu cardboard, glass, metal, paper, plastic, dan trash. Setiap gambar hanya memiliki satu label, sehingga problem ini termasuk ke dalam **multi-class image classification**.

Tujuan utama dari model ini adalah membantu proses identifikasi jenis sampah secara otomatis berdasarkan gambar. Dengan model seperti ini, sistem dapat dikembangkan lebih lanjut untuk aplikasi seperti smart waste classification, recycling support system, atau sistem pemilahan sampah otomatis.

Pada project ini, dua model CNN dibuat dan dibandingkan, yaitu **Baseline CNN** dan **Improved CNN**. Baseline CNN digunakan sebagai model awal untuk mengetahui performa dasar, sedangkan Improved CNN dibuat sebagai pengembangan dengan arsitektur yang lebih stabil dan lebih kuat. Selain itu, karena model awal menunjukkan performa recall yang rendah pada kelas glass, dilakukan penyesuaian class weight untuk membantu model lebih memperhatikan kelas tersebut.

2. Dataset Description

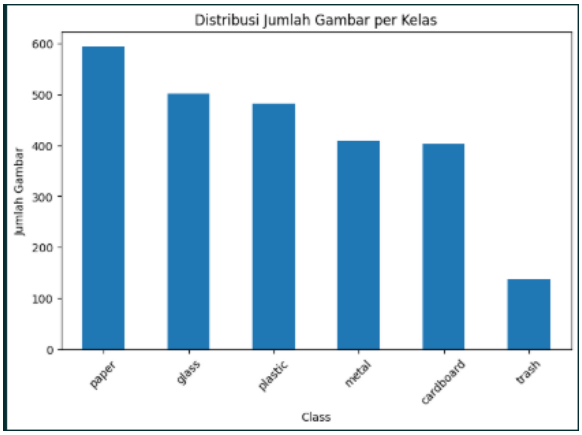
Dataset terdiri dari gambar berbagai jenis sampah yang sudah dikelompokkan ke dalam folder berdasarkan kelasnya. Struktur dataset terdiri dari enam kelas, yaitu paper, glass, plastic, metal, cardboard, dan trash.

Total gambar pada dataset adalah **2527 gambar**. Distribusi gambar pada setiap kelas tidak seimbang. Kelas paper, glass, dan plastic memiliki jumlah data yang lebih banyak, sedangkan kelas trash memiliki jumlah data paling sedikit.

Distribusi data pada dataset adalah sebagai berikut:

Class	Jumlah Gambar
paper	594
glass	501
plastic	482
metal	410
cardboard	403
trash	137

Dari distribusi tersebut, dapat dilihat bahwa dataset mengalami **class imbalance**. Class imbalance ini dapat menyebabkan model lebih mudah belajar pada kelas mayoritas dan lebih sulit mengenali kelas minoritas. Oleh karena itu, pada tahap training digunakan class weight agar model tidak terlalu bias terhadap kelas dengan jumlah gambar yang lebih banyak.



Gambar 1. Distribusi jumlah gambar per kelas

3. Preprocessing Methods

Tahap preprocessing dilakukan untuk memastikan data gambar siap digunakan dalam proses training model CNN. Preprocessing sangat penting karena kualitas input data sangat mempengaruhi performa model deep learning.

3.1 Membuat DataFrame Path dan Label

Langkah pertama adalah membaca semua gambar dari folder dataset dan menyimpannya ke dalam dataframe. Dataframe berisi dua kolom utama, yaitu image_path dan label. Kolom image_path menyimpan lokasi gambar, sedangkan kolom label menyimpan nama kelas dari gambar tersebut.

Pendekatan ini digunakan agar proses analisis, splitting data, dan evaluasi menjadi lebih mudah. Dengan dataframe, setiap gambar dapat dilacak berdasarkan path dan labelnya.

3.2 Label Encoding

Label yang awalnya berbentuk teks seperti cardboard, glass, metal, paper, plastic, dan trash diubah menjadi angka. Hal ini perlu dilakukan karena model deep learning tidak dapat langsung memproses label berbentuk string.

Mapping label yang digunakan adalah:

Label	Index
cardboard	0
glass	1
metal	2
paper	3
plastic	4
trash	5

Selain itu, label juga diubah menjadi bentuk **one-hot encoding**. Karena jumlah kelas adalah 6, maka setiap label direpresentasikan sebagai vector dengan panjang 6. Format ini cocok digunakan karena output layer model menggunakan activation function softmax dan loss function categorical_crossentropy.

3.3 Data Splitting

Dataset dibagi menjadi tiga bagian, yaitu training set, validation set, dan testing set. Rasio pembagian data yang digunakan adalah:

Training set = 70%
Validation set = 15%
Testing set = 15%

Hasil pembagian data adalah:

Subset	Jumlah Gambar
Training set	1768
Validation set	379
Testing set	380

Pembagian data dilakukan menggunakan **stratified split**. Stratified split digunakan agar distribusi setiap kelas tetap terjaga pada training, validation, dan testing set. Hal ini penting karena dataset memiliki class imbalance. Jika data dibagi secara acak tanpa stratification, kelas minoritas seperti trash bisa saja memiliki jumlah data yang terlalu sedikit pada validation atau test set.

Setelah splitting, distribusi kelas tetap muncul pada semua subset. Hal ini menunjukkan bahwa proses stratified split berhasil menjaga proporsi kelas dengan baik.

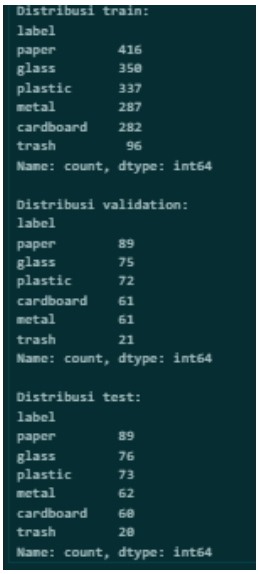


Figure 2. Distribusi kelas setelah train-validation-test split

3.4 Image Resizing

Semua gambar diubah ukurannya menjadi **224 × 224 piksel**. Resize diperlukan karena model CNN membutuhkan input dengan ukuran yang konsisten. Ukuran 224 × 224 dipilih karena umum digunakan dalam CNN dan transfer learning model seperti MobileNet, ResNet, dan EfficientNet.

Dengan ukuran ini, gambar masih memiliki detail yang cukup untuk dipelajari oleh model, tetapi tidak terlalu besar sehingga training tetap efisien.

3.5 Normalization

Nilai pixel gambar awalnya berada pada rentang 0 sampai 255. Pada preprocessing, nilai pixel dinormalisasi menjadi rentang 0 sampai 1 dengan cara membagi nilai pixel dengan 255.

Normalisasi ini dilakukan agar proses training lebih stabil. Neural network biasanya lebih mudah belajar jika input berada pada skala kecil dan konsisten.

3.6 TensorFlow Data Pipeline

Dataset kemudian diubah menjadi TensorFlow dataset pipeline menggunakan tf.data.Dataset. Pipeline ini terdiri dari beberapa tahap, yaitu membaca gambar, resize, normalisasi, one-hot encoding label, batching, caching, dan prefetching.

Pipeline ini digunakan agar proses training lebih efisien. cache() membantu menyimpan hasil preprocessing sehingga tidak perlu diproses ulang pada setiap epoch. shuffle() digunakan pada training set agar model tidak belajar berdasarkan urutan data. batch() digunakan agar model memproses beberapa gambar sekaligus, dan prefetch() digunakan agar batch berikutnya dapat disiapkan saat model sedang melakukan training.

Hasil pengecekan shape dataset adalah:

Image batch shape: (32, 224, 224, 3)
Label batch shape: (32, 6)

Artinya, setiap batch berisi 32 gambar, setiap gambar memiliki ukuran 224 × 224 dengan 3 channel RGB, dan setiap label memiliki 6 output sesuai jumlah kelas.

3.7 Data Augmentation

Data augmentation diterapkan pada training data untuk meningkatkan variasi gambar. Augmentation yang digunakan meliputi:

RandomFlip("horizontal")
RandomRotation(0.05)
RandomZoom(0.05)
RandomTranslation(0.03,0.03)
RandomContrast(0.08)

Tujuan penggunaan augmentation adalah agar model tidak hanya menghafal gambar training, tetapi mampu mengenali objek dalam berbagai kondisi, seperti posisi sedikit bergeser, objek sedikit miring, ukuran sedikit berubah, dan pencahayaan berbeda.

Sebelum mendapatkan konfigurasi final, beberapa kombinasi augmentation sempat dicoba. Pada percobaan awal, nilai rotation, zoom, dan translation dibuat lebih besar. Hasil visualisasi menunjukkan bahwa beberapa gambar menjadi terlalu blur, muncul distortion pada pinggir gambar, dan detail objek mulai berkurang. Oleh karena itu, parameter augmentation dikurangi secara bertahap sampai diperoleh konfigurasi yang lebih stabil.

Konfigurasi final dipilih karena hasil visualisasinya tetap realistis. Objek masih terlihat jelas, tidak terlalu blur, tidak memiliki distortion yang mengganggu, dan tetap memberikan variasi yang cukup untuk training. Augmentation hanya diterapkan pada training set, sedangkan validation dan testing set tetap menggunakan gambar asli agar evaluasi tetap adil.

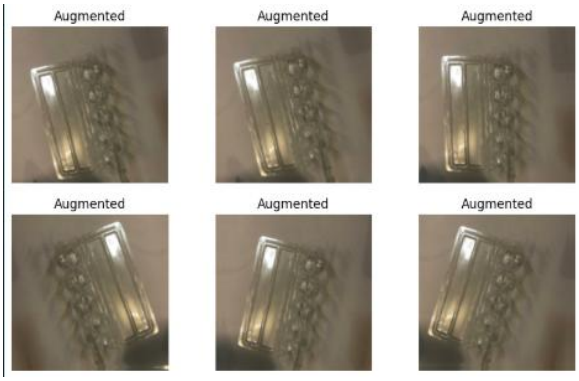


Figure 3. Contoh hasil data augmentation

3.8 Class Weight dan Custom Class Weight

Karena dataset memiliki class imbalance, digunakan class weight agar model memberikan perhatian lebih besar pada kelas dengan jumlah data lebih sedikit. Class weight dihitung menggunakan compute_class_weight() dengan mode balanced.

Hasil class weight menunjukkan bahwa kelas trash memiliki bobot paling besar karena jumlah gambarnya paling sedikit. Sebaliknya, kelas paper memiliki bobot lebih kecil karena jumlah gambarnya paling banyak.

Selain class weight standar, dilakukan juga penyesuaian pada kelas glass. Berdasarkan hasil evaluasi awal(percobaan-percobaan yang tidak dimasukkan ke dalam final code), kelas glass memiliki recall yang rendah. Model masih sering salah mengenali gambar kaca sebagai kelas lain seperti metal, plastic, atau trash. Oleh karena itu, bobot kelas glass dinaikkan secara manual menjadi 1.3 dengan pertimbangan tidak terlalu besar dan kecil untuk jumlahd data.

Tujuan custom class weight ini adalah agar model memberikan penalti loss yang lebih besar ketika salah memprediksi kelas glass. Dengan begitu, model diharapkan lebih fokus mempelajari karakteristik visual kelas glass.

4. Model yang Digunakan

Pada project ini digunakan dua model CNN, yaitu Baseline CNN dan Improved CNN. Keduanya digunakan untuk membandingkan performa model sederhana dan model yang sudah dimodifikasi.

CNN atau Convolutional Neural Network digunakan karena project ini berhubungan dengan data gambar. CNN merupakan model deep learning yang sangat cocok untuk image classification karena mampu mempelajari pola visual secara otomatis dari gambar, seperti warna, edge, tekstur, bentuk, hingga pola objek yang lebih kompleks. Berbeda dengan model machine learning biasa yang biasanya membutuhkan feature extraction manual, CNN dapat melakukan feature extraction secara langsung melalui convolution layer.

Model CNN dipilih karena dataset pada project ini memiliki beberapa kelas gambar yang perlu diklasifikasikan. Dalam kasus klasifikasi gambar, informasi visual seperti bentuk objek, warna, sudut, tekstur, dan pola lokal sangat penting. CNN memiliki convolution layer yang dapat menangkap informasi tersebut dengan baik. Oleh karena itu, CNN menjadi pilihan yang sesuai

untuk membangun model klasifikasi gambar pada project ini.

Selain itu, digunakan dua model agar proses eksperimen menjadi lebih jelas. Baseline CNN digunakan sebagai model awal untuk mengetahui performa dasar CNN sederhana. Improved CNN kemudian dibuat untuk melihat apakah penambahan teknik seperti BatchNormalization, GlobalAveragePooling2D, convolution block tambahan, dan class weight dapat meningkatkan performa model. Dengan membandingkan kedua model ini, peningkatan performa dapat dianalisis secara lebih objektif.

4.1 Baseline CNN

Baseline CNN digunakan sebagai model awal untuk mengetahui performa dasar dari CNN sederhana. Model ini terdiri dari beberapa layer utama:

Input Layer
Data Augmentation
Conv2D + MaxPooling
Conv2D + MaxPooling
Conv2D + MaxPooling
Flatten
Dense
Dropout
Softmax Output

Baseline CNN digunakan karena model ini dapat menjadi acuan awal sebelum dilakukan pengembangan model yang lebih kompleks. Dengan menggunakan baseline, kita dapat mengetahui apakah arsitektur CNN sederhana sudah mampu mempelajari pola pada dataset gambar. Hasil dari baseline model juga dapat digunakan sebagai pembanding untuk menilai apakah Improved CNN benar-benar memberikan peningkatan performa atau tidak.

Model baseline dibuat sederhana agar proses training lebih mudah dianalisis. Jika model terlalu kompleks sejak awal, akan lebih sulit mengetahui apakah peningkatan performa disebabkan oleh arsitektur model, preprocessing, augmentasi, atau faktor lainnya. Oleh karena itu, baseline model penting sebagai titik awal eksperimen.

Model menggunakan tiga convolution layer dengan jumlah filter 32, 64, dan 128. Jumlah filter dibuat meningkat secara bertahap karena semakin dalam layer CNN, fitur yang dipelajari biasanya semakin kompleks. Layer awal belajar fitur sederhana seperti edge, warna, dan tekstur dasar, sedangkan layer yang lebih dalam belajar bentuk dan pola objek yang lebih kompleks.

Activation function yang digunakan pada hidden layer adalah ReLU. ReLU dipilih karena cocok untuk CNN, ringan secara komputasi, dan membantu mengurangi masalah vanishing gradient. ReLU juga memungkinkan model mempelajari pola non-linear pada gambar.

Setelah convolution layer, digunakan Flatten() untuk mengubah feature map menjadi vector satu dimensi. Kemudian digunakan Dense layer dengan 128 neuron dan Dropout sebesar 0.4 untuk mengurangi overfitting.

Dropout digunakan karena model CNN berpotensi mengalami overfitting, terutama jika dataset memiliki jumlah gambar yang terbatas atau terdapat ketidakseimbangan antar kelas. Dengan Dropout, sebagian neuron akan dinonaktifkan secara acak selama training sehingga model tidak terlalu bergantung pada pola tertentu saja. Hal ini membantu model agar dapat melakukan generalisasi lebih baik pada data validation dan test.

Output layer menggunakan Softmax karena task ini merupakan multi-class classification. Softmax menghasilkan probabilitas untuk setiap kelas, dan kelas dengan probabilitas tertinggi menjadi hasil prediksi model.

Baseline CNN dikompilasi menggunakan:

Optimizer: Adam
Learning rate: 1e-4
Loss: categorical_crossentropy
Metrics: accuracy, precision, recall

Optimizer Adam digunakan karena Adam merupakan optimizer yang umum digunakan dalam deep learning dan mampu menyesuaikan learning rate secara adaptif selama proses training. Learning rate 1e-4 digunakan agar proses training lebih stabil dan tidak terlalu agresif. Loss function categorical_crossentropy digunakan karena task ini merupakan multi-class classification dengan output Softmax.

Metrics yang digunakan adalah accuracy, precision, dan recall. Accuracy digunakan untuk melihat persentase prediksi yang benar secara keseluruhan. Precision digunakan untuk melihat seberapa tepat model ketika memprediksi suatu kelas, sedangkan recall digunakan untuk melihat seberapa baik model dalam menemukan seluruh data dari suatu kelas. Penggunaan precision dan recall penting karena pada dataset klasifikasi gambar, performa model tidak cukup hanya dilihat dari accuracy, terutama jika terdapat kelas yang lebih sulit atau jumlah datanya tidak seimbang.

Baseline model ini penting karena menjadi acuan awal. Jika model yang lebih kompleks menghasilkan performa lebih baik, maka peningkatannya dapat dibandingkan terhadap baseline.

4.2 Improved CNN

Improved CNN dibuat sebagai pengembangan dari Baseline CNN. Model ini memiliki beberapa peningkatan utama:

Penambahan convolution block BatchNormalization setelah convolution layer GlobalAveragePooling2D sebagai pengganti Flatten
Dense layer yang lebih besar
Custom class weight untuk kelas glass

Improved CNN digunakan karena baseline model masih memiliki keterbatasan dalam mempelajari pola visual yang lebih kompleks. Model baseline sederhana biasanya cukup baik untuk menangkap fitur dasar, tetapi pada dataset gambar dengan banyak variasi, model membutuhkan kapasitas yang lebih besar agar dapat mengenali pola yang lebih detail. Oleh karena itu, Improved CNN dibuat untuk meningkatkan kemampuan model dalam mengenali perbedaan antar kelas.

Arsitektur Improved CNN terdiri dari empat convolution block dengan jumlah filter 32, 64, 128, dan 256. Penambahan filter sampai 256 membuat model memiliki kapasitas lebih besar untuk mempelajari fitur visual yang lebih kompleks.

Jumlah convolution block ditambah karena semakin dalam model CNN, semakin banyak level fitur yang dapat dipelajari. Layer awal dapat mempelajari fitur sederhana seperti garis, warna, dan tekstur dasar. Layer tengah dapat mempelajari pola yang lebih kompleks seperti sudut, bentuk kecil, atau bagian objek. Layer yang lebih dalam dapat mempelajari fitur tingkat tinggi yang lebih relevan untuk membedakan kelas gambar.

Setelah setiap convolution layer, digunakan BatchNormalization. Batch Normalization membantu menstabilkan training dengan menormalkan output dari layer sebelumnya. Hal ini membuat proses training lebih stabil dan dapat membantu model belajar lebih baik.

BatchNormalization digunakan karena CNN yang lebih dalam biasanya lebih sulit dilatih dibandingkan model sederhana. Dengan BatchNormalization, distribusi aktivasi pada setiap layer menjadi lebih stabil, sehingga model dapat belajar dengan lebih konsisten. Teknik ini

juga dapat membantu mempercepat convergence dan mengurangi risiko training yang tidak stabil.

Pada Baseline CNN, digunakan Flatten(). Namun pada Improved CNN, digunakan GlobalAveragePooling2D. Layer ini mengurangi jumlah parameter dengan cara mengambil rata-rata dari setiap feature map. Hal ini membantu mengurangi risiko overfitting dan membuat model lebih efisien.

GlobalAveragePooling2D dipilih karena Flatten dapat menghasilkan jumlah parameter yang sangat besar, terutama jika feature map masih berukuran cukup besar. Jumlah parameter yang terlalu banyak dapat membuat model lebih mudah overfitting. Dengan GlobalAveragePooling2D, model tetap dapat mengambil informasi penting dari feature map, tetapi dengan jumlah parameter yang lebih sedikit. Hal ini membuat model lebih ringan dan lebih mampu melakukan generalisasi.

Improved CNN juga menggunakan Dense layer dengan 256 neuron dan Dropout sebesar 0.4. Dense layer yang lebih besar digunakan agar model memiliki kapasitas lebih baik dalam mempelajari kombinasi fitur dari convolution layer. Dropout tetap digunakan untuk mengurangi risiko overfitting.

Output layer tetap menggunakan Softmax karena dataset memiliki enam kelas. Softmax digunakan untuk menghasilkan probabilitas pada masing-masing kelas, sehingga model dapat menentukan kelas dengan probabilitas tertinggi sebagai hasil prediksi.

Improved CNN dikompilasi dengan konfigurasi yang sama:

Optimizer: Adam
Learning rate: 1e-4
Loss: categorical_crossentropy
Metrics: accuracy, precision, recall

Konfigurasi compile dibuat sama dengan baseline agar perbandingan antara Baseline CNN dan Improved CNN lebih adil. Dengan optimizer, learning rate, loss function, dan metrics yang sama, perbedaan performa lebih dapat dikaitkan dengan perubahan arsitektur model, bukan karena perbedaan konfigurasi training.

Custom class weight untuk kelas glass digunakan karena kelas tersebut membutuhkan perhatian lebih dari model. Jika terdapat kelas yang lebih sulit dikenali atau jumlah datanya lebih sedikit, model dapat cenderung bias terhadap kelas lain yang lebih dominan. Dengan memberikan class weight, model akan memberikan penalti lebih besar ketika salah memprediksi kelas tersebut. Hal ini membantu model agar lebih memperhatikan kelas yang sulit dan meningkatkan performa klasifikasi pada kelas tersebut.

Secara keseluruhan, Improved CNN digunakan untuk meningkatkan kemampuan model dalam mempelajari fitur visual yang lebih kompleks, menstabilkan proses training, mengurangi risiko overfitting, dan menangani kelas yang lebih sulit. Model ini diharapkan dapat memberikan performa yang lebih baik dibandingkan Baseline CNN.

5. Training dan Validation Results

5.1 Training Baseline CNN

Baseline CNN dilatih selama 10 epoch. Pada awal training, performa model masih rendah karena model belum banyak mempelajari pola visual dari dataset. Pada epoch pertama, training accuracy sebesar 25.68% dan validation accuracy sebesar 30.34%.

Seiring bertambahnya epoch, validation accuracy meningkat secara bertahap. Hasil terbaik Baseline CNN diperoleh pada epoch 10 dengan nilai:

Metric	Nilai
Training Accuracy	0.5187
Training Loss	1.1788
Training Precision	0.7354
Training Recall	0.2986
Validation Accuracy	0.5251
Validation Loss	1.2595
Validation Precision	0.7174
Validation Recall	0.3483

Hasil ini menunjukkan bahwa Baseline CNN sudah mampu belajar sebagian pola dari dataset, tetapi performanya masih belum optimal. Validation recall yang rendah menunjukkan bahwa model masih belum mampu menangkap banyak data asli dari setiap kelas.

Baseline CNN hanya dilatih selama 10 epoch karena sebelumnya sempat dicoba dengan epoch lebih banyak, tetapi hasilnya masih belum maksimal. Selain itu, setelah kernel notebook sempat restart, proses training ulang dengan 30 epoch membutuhkan waktu cukup lama. Oleh karena itu, baseline dilatih ulang dengan 10 epoch agar tetap dapat digunakan sebagai pembanding awal. Namun, perlu dicatat bahwa perbandingan dengan Improved CNN menjadi kurang sepenuhnya fair karena jumlah epoch berbeda.

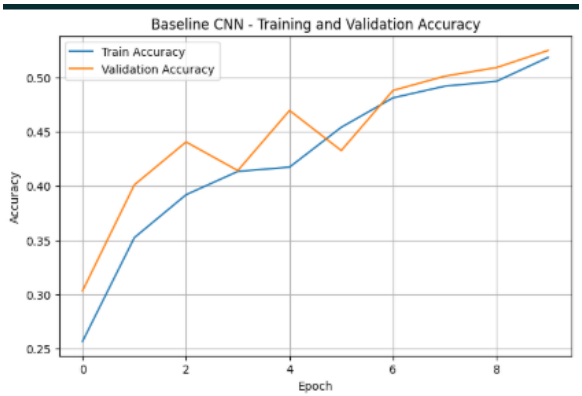


Figure 4. Grafik training dan validation accuracy Baseline CNN

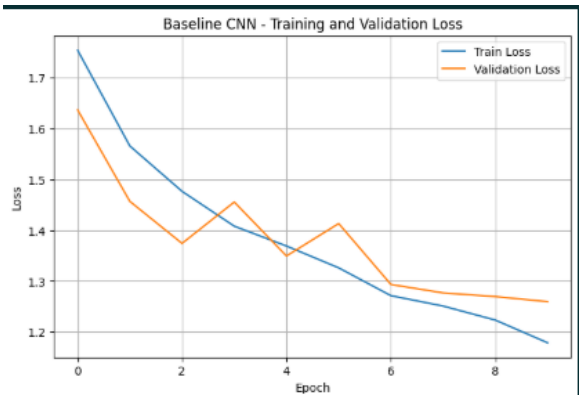


Figure 5. Grafik training dan validation loss Baseline CNN

5.2 Training Improved CNN

Improved CNN dilatih dengan maksimum 30 epoch menggunakan custom class weight untuk kelas glass. Pada awal training, validation accuracy masih rendah, yaitu 23.48% pada epoch pertama. Hal ini wajar karena model belum mempelajari pola visual secara optimal.
Seiring bertambahnya epoch, performa model meningkat dengan cukup signifikan. Validation accuracy naik dari 23.48% pada epoch 1, menjadi 48.02% pada epoch 8, 65.96% pada epoch 11, 71.24% pada epoch 17, dan 74.67% pada epoch 20.

Hasil terbaik diperoleh pada epoch 24 dengan nilai:

Metric	Nilai
Validation Accuracy	0.7863
Validation Loss	0.7122
Validation Precision	0.8502
Validation Recall	0.6887

Pada akhir training, callback mengembalikan bobot model ke epoch 24 karena epoch tersebut memiliki validation accuracy terbaik. Meskipun training berjalan sampai epoch 30, model final menggunakan bobot terbaik dari epoch 24.
Hasil ini menunjukkan bahwa Improved CNN memiliki kemampuan generalisasi yang jauh lebih baik dibandingkan baseline. Validation accuracy yang tinggi dan validation loss yang lebih rendah menunjukkan bahwa model berhasil mempelajari pola visual dengan lebih stabil.

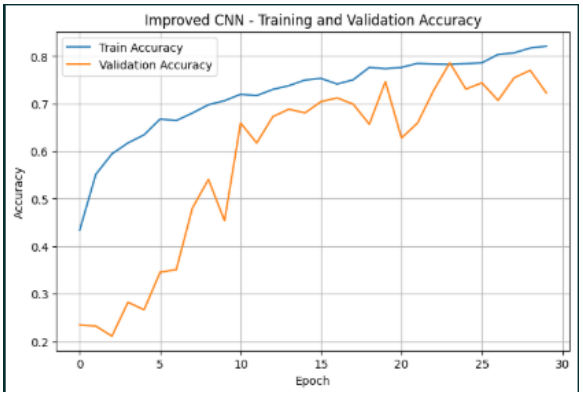


Figure 6. Grafik training dan validation accuracy Improved CNN

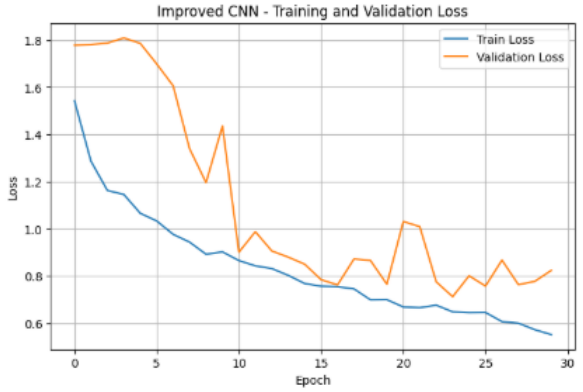


Figure 7. Grafik training dan validation loss Improved CNN

6. Evaluation Results
Setelah training selesai, kedua model dievaluasi menggunakan test set. Test set berisi 380 gambar yang tidak digunakan selama training maupun validation.

6.1 Hasil Evaluasi Baseline CNN

Hasil evaluation Baseline CNN adalah:

Metric	Nilai
Test Loss	1.191789
Test Accuracy	0.547368
Test Precision	0.739362
Test Recall	0.365789
Training Time	371.33 seconds

Baseline CNN memperoleh test accuracy sebesar **54.74%**. Precision sebesar 73.94% menunjukkan bahwa ketika model memprediksi suatu kelas, prediksi tersebut cukup sering benar. Namun, recall hanya 36.58%, yang berarti model masih banyak gagal menangkap data asli dari setiap kelas.
Classification report Baseline CNN menunjukkan bahwa kelas glass memiliki recall yang rendah, yaitu 0.33. Hal ini berarti model masih sering gagal mengenali gambar glass. Kelas trash memiliki recall tinggi sebesar 0.90, tetapi precision-nya hanya 0.38, yang menunjukkan bahwa model terlalu sering memprediksi gambar sebagai trash meskipun tidak semuanya benar.
Secara keseluruhan, Baseline CNN masih memiliki performa terbatas. Weighted f1-score hanya 0.55, sehingga model ini belum cukup kuat untuk membedakan seluruh kelas dengan baik.

6.2 Hasil Evaluasi Improved CNN

Hasil evaluation Improved CNN adalah:

Metric	Nilai
Test Loss	0.586481
Test Accuracy	0.802632
Test Precision	0.871473
Test Recall	0.731579
Training Time	11892.25 seconds

Improved CNN memperoleh test accuracy sebesar **80.26%**, jauh lebih tinggi dibandingkan Baseline CNN. Test loss juga turun dari 1.1918 menjadi 0.5865. Hal ini menunjukkan bahwa Improved CNN menghasilkan prediksi yang lebih akurat dan lebih stabil.
Precision sebesar 87.15% menunjukkan bahwa model lebih tepat dalam memprediksi kelas. Recall sebesar 73.16% menunjukkan bahwa model jauh lebih baik dalam mengenali data asli dari setiap kelas.

Classification report Improved CNN menunjukkan hasil yang jauh lebih seimbang:

Class	Precision	Recall	F1-score
cardboard	0.94	0.77	0.84
glass	0.75	0.74	0.74
metal	0.74	0.77	0.76
paper	0.85	0.93	0.89
plastic	0.75	0.79	0.77
trash	0.88	0.70	0.78

Hasil ini menunjukkan bahwa custom class weight berhasil membantu meningkatkan performa kelas glass. Pada Baseline CNN, recall glass hanya 0.33. Pada Improved CNN, recall glass meningkat menjadi 0.74. Peningkatan ini menunjukkan bahwa model menjadi jauh lebih baik dalam mengenali gambar glass.
Weighted average f1-score Improved CNN adalah 0.80, jauh lebih tinggi dibandingkan Baseline CNN yang hanya 0.55. Hal ini membuktikan bahwa Improved CNN memiliki performa yang lebih baik secara keseluruhan.

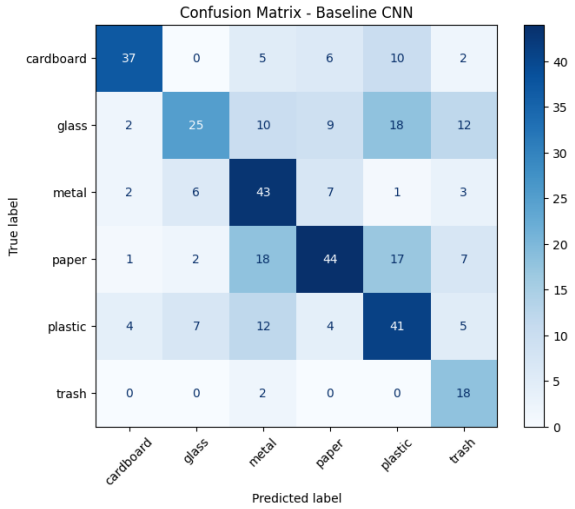


Figure 8. Confusion Matrix Baseline CNN

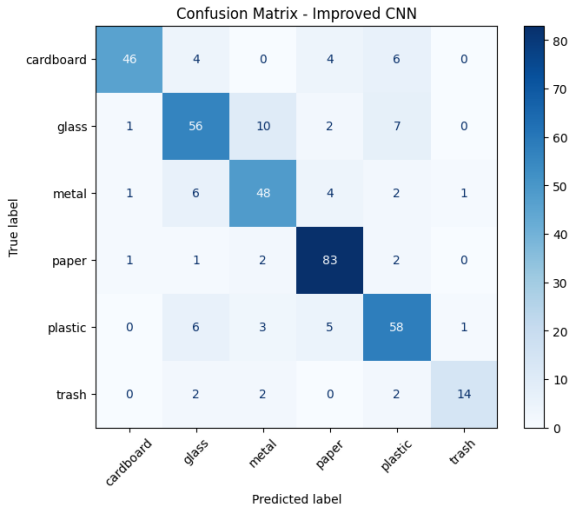


Figure 9. Confusion Matrix Improved CNN

6.3 Perbandingan Baseline CNN dan Improved CNN

Perbandingan hasil kedua model adalah sebagai berikut:

Model	Test Loss	Test Accuracy	Test Precision	Test Recall	Training Time
Baseline CNN	1.191789	0.547368	0.739362	0.365789	371.33 sec
Improved CNN	0.586481	0.802632	0.871473	0.731579	11892.25 sec

Dari tabel tersebut, dapat dilihat bahwa Improved CNN lebih unggul pada semua metric utama. Test accuracy meningkat dari 54.74% menjadi 80.26%. Test precision meningkat dari 73.94% menjadi 87.15%. Test recall meningkat dari 36.58% menjadi 73.16%.

Peningkatan terbesar terlihat pada recall. Hal ini penting karena recall menunjukkan kemampuan model untuk menemukan data asli dari setiap kelas. Baseline CNN cenderung gagal menangkap banyak data dari beberapa kelas, terutama glass. Setelah arsitektur diperbaiki dan custom class weight diterapkan, Improved CNN mampu mengenali kelas-kelas dengan jauh lebih baik.

Improved CNN bisa menghasilkan performa yang lebih baik karena beberapa alasan. Pertama, arsitekturnya lebih dalam sehingga mampu menangkap fitur visual yang lebih kompleks. Kedua, BatchNormalization membantu training menjadi lebih stabil. Ketiga, GlobalAveragePooling2D mengurangi jumlah parameter dan risiko overfitting dibanding Flatten. Keempat, custom class weight untuk glass membuat model lebih memperhatikan kelas yang sebelumnya sulit dikenali.

Namun, Improved CNN membutuhkan waktu training yang jauh lebih lama. Hal ini wajar karena model memiliki arsitektur lebih kompleks dan dilatih lebih lama. Meskipun begitu, peningkatan performa yang diperoleh cukup signifikan, sehingga Improved CNN dipilih sebagai model akhir yang lebih baik.

7. Interpretasi Model Menggunakan Attention Map / Grad-CAM

Selain evaluasi menggunakan metric seperti accuracy, precision, recall, f1-score, dan confusion matrix, model juga dianalisis menggunakan attention map visualization dengan metode Grad-CAM. Grad-CAM digunakan untuk melihat bagian gambar yang paling diperhatikan oleh model CNN ketika membuat prediksi. Visualisasi ini penting karena CNN sering dianggap sebagai black-box model, sehingga Grad-CAM dapat membantu menjelaskan apakah model benar-benar memperhatikan objek utama atau justru terlalu fokus pada background.

Grad-CAM bekerja dengan memanfaatkan feature map dari convolution layer terakhir dan gradient dari kelas prediksi. Pada project ini, Grad-CAM diterapkan pada model Improved CNN karena model tersebut merupakan model dengan performa terbaik berdasarkan hasil evaluasi. Layer yang digunakan adalah convolution layer terakhir dari Improved CNN, yaitu improved_last_conv_layer. Layer ini dipilih karena convolution layer terakhir biasanya menyimpan informasi visual tingkat tinggi yang masih memiliki hubungan spasial dengan gambar asli.

Hasil visualisasi Grad-CAM ditampilkan dalam tiga bagian, yaitu original image, heatmap, dan overlay. Original image menunjukkan gambar input asli. Heatmap menunjukkan area yang

dianggap penting oleh model, sedangkan overlay merupakan gabungan antara gambar asli dan heatmap. Area dengan warna lebih panas menunjukkan bagian gambar yang memiliki kontribusi lebih besar terhadap keputusan model.

Berdasarkan hasil Grad-CAM pada salah satu gambar test, model Improved CNN berhasil memprediksi kelas dengan benar. Pada contoh gambar dengan true label trash, model juga memprediksi kelas tersebut sebagai trash dengan confidence sekitar 0.61. Heatmap terlihat berada pada area objek sampah yang cukup dominan. Hal ini menunjukkan bahwa model tidak hanya menebak secara acak, tetapi memperhatikan bagian visual yang berhubungan dengan objek utama pada gambar.

Grad-CAM juga dibuat secara khusus untuk kelas glass karena kelas ini sebelumnya memiliki recall yang rendah pada model awal. Setelah menggunakan Improved CNN dan custom class weight, beberapa gambar glass berhasil diprediksi dengan benar. Hasil ini menunjukkan bahwa model sudah lebih mampu mengenali karakteristik visual kaca. Namun, confidence pada beberapa gambar glass masih berada pada tingkat sedang. Hal ini wajar karena objek kaca memiliki karakteristik visual yang sulit, seperti transparansi, pantulan cahaya, dan kemiripan dengan objek plastic atau metal.

Selain prediksi yang benar, Grad-CAM juga membantu menganalisis prediksi yang salah. Pada salah satu contoh, gambar dengan true label glass diprediksi sebagai kelas lain. Dari hasil heatmap, terlihat bahwa model tidak sepenuhnya fokus pada objek kaca, tetapi juga memperhatikan area background. Hal ini menunjukkan bahwa background, pencahayaan, ukuran objek yang kecil, atau posisi objek yang kurang jelas masih dapat memengaruhi keputusan model.

Secara keseluruhan, hasil attention map menunjukkan bahwa Improved CNN sudah memiliki pola perhatian visual yang cukup baik, terutama pada prediksi yang benar. Model umumnya sudah mampu memperhatikan area objek utama. Namun, beberapa kesalahan prediksi menunjukkan bahwa model masih dapat terpengaruh oleh background atau objek yang kurang jelas. Oleh karena itu, Grad-CAM tidak hanya membantu menjelaskan hasil prediksi model, tetapi juga membantu menemukan kelemahan model yang masih dapat diperbaiki pada pengembangan berikutnya.

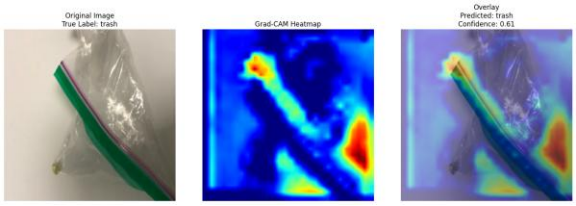


Figure 10. Grad-CAM untuk salah satu gambar test

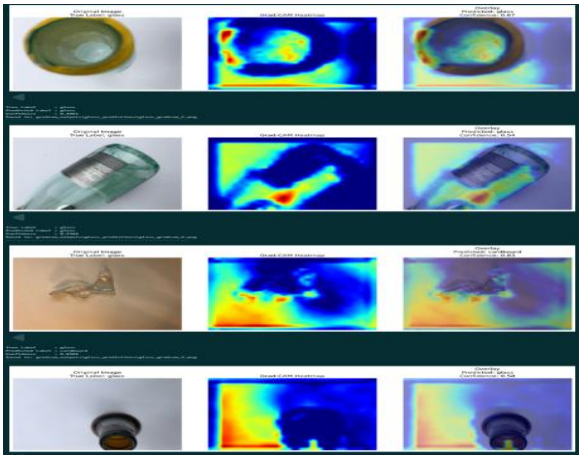


Figure 11. Grad-CAM khusus kelas glass

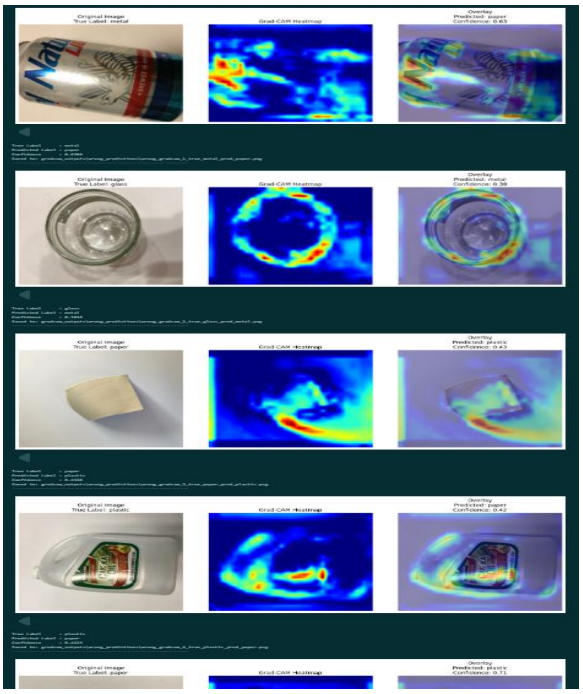


Figure 12. Grad-CAM pada prediksi yang salah

8. Challenges and Future Opportunities

8.1 Existing Challenges

Meskipun Improved CNN sudah menghasilkan performa yang cukup baik, masih terdapat beberapa tantangan yang perlu diperhatikan.
Tantangan pertama adalah class imbalance. Jumlah gambar pada setiap kelas tidak sama, terutama kelas trash yang memiliki jumlah data paling sedikit. Meskipun class weight sudah digunakan, jumlah data yang terbatas tetap dapat memengaruhi performa model, terutama dalam mengenali kelas minoritas secara optimal.

Tantangan kedua adalah visual similarity antar kelas. Beberapa kelas memiliki karakter visual yang mirip, misalnya glass, plastic, dan metal. Objek kaca dan plastik bisa sama-sama transparan, reflektif, atau memiliki permukaan mengkilap. Kondisi ini dapat membuat model mengalami kesulitan dalam membedakan kelas-kelas tersebut, terutama jika objek pada gambar tidak terlihat jelas.

Tantangan ketiga adalah variasi background dan pencahayaan. Gambar pada dataset memiliki kondisi pencahayaan dan background yang berbeda-beda. Hal ini dapat memengaruhi kemampuan model dalam fokus pada objek utama. Berdasarkan hasil Grad-CAM, pada beberapa kasus model masih dapat memperhatikan area background, bukan sepenuhnya objek utama. Hal ini menunjukkan bahwa kualitas gambar dan kondisi pengambilan gambar masih dapat memengaruhi hasil prediksi model.

Tantangan keempat adalah training time. Improved CNN membutuhkan waktu training yang jauh lebih lama dibandingkan Baseline CNN. Hal ini wajar karena Improved CNN memiliki arsitektur yang lebih kompleks dan dilatih dengan epoch yang lebih banyak. Namun, waktu training yang lama dapat menjadi kendala jika eksperimen perlu dilakukan berulang kali.
Tantangan kelima adalah perbandingan model yang belum sepenuhnya fair. Baseline CNN dilatih selama 10 epoch, sedangkan Improved CNN dilatih sampai 30 epoch. Perbedaan jumlah epoch ini membuat Improved CNN memiliki kesempatan belajar lebih lama dibandingkan Baseline CNN. Untuk eksperimen yang lebih adil, kedua model sebaiknya dilatih dengan jumlah epoch yang sama.

8.2 Future Opportunities

Ada beberapa peluang pengembangan yang dapat dilakukan untuk meningkatkan performa model.
Pertama, model dapat dikembangkan menggunakan transfer learning seperti MobileNetV2, ResNet50, EfficientNetB0, atau DenseNet. Model pretrained biasanya memiliki kemampuan feature extraction yang lebih baik karena sudah dilatih pada dataset besar seperti ImageNet. Dengan transfer learning, model diharapkan dapat mengenali pola visual dengan lebih baik dan mencapai performa yang lebih tinggi.

Kedua, dataset dapat ditambah, terutama untuk kelas minoritas seperti trash. Dengan jumlah data yang lebih seimbang, model dapat belajar lebih baik pada seluruh kelas. Penambahan data juga dapat membantu model mengurangi bias terhadap kelas mayoritas.

Ketiga, dapat dilakukan fine-tuning pada model pretrained. Fine-tuning memungkinkan model menyesuaikan fitur yang sudah dipelajari sebelumnya dengan karakteristik dataset sampah. Dengan cara ini, model dapat mempelajari detail visual yang lebih spesifik dari setiap kelas.

Keempat, dapat dilakukan eksperimen dengan focal loss sebagai alternatif class weight. Focal loss dapat membantu model lebih fokus pada sample yang sulit diklasifikasikan. Teknik ini dapat menjadi pilihan untuk menangani class imbalance dan meningkatkan performa pada kelas yang sering salah diprediksi.

Kelima, interpretasi model dapat diperluas menggunakan Grad-CAM pada lebih banyak gambar. Dengan Grad-CAM, dapat dianalisis apakah model benar-benar fokus pada objek sampah atau justru masih dipengaruhi oleh background. Hasil interpretasi ini dapat digunakan untuk memperbaiki preprocessing, augmentasi, atau pemilihan arsitektur model.

Keenam, evaluasi dapat diperluas menggunakan macro F1-score, weighted F1-score, dan confusion matrix analysis agar performa model dapat dianalisis lebih detail pada setiap kelas. Dengan evaluasi yang lebih lengkap, kelemahan model pada kelas tertentu dapat terlihat lebih jelas.

9. Conclusion

Project ini berhasil membangun dan mengevaluasi model CNN untuk klasifikasi gambar sampah ke dalam enam kelas, yaitu cardboard, glass, metal, paper, plastic, dan trash. Tahap preprocessing dilakukan dengan cukup lengkap, meliputi pembuatan dataframe path-label, label encoding, stratified data splitting, image resizing, normalization, TensorFlow data pipeline, data augmentation, class weight, dan custom class weight untuk kelas glass.

Dua model dibuat dan dibandingkan, yaitu Baseline CNN dan Improved CNN. Baseline CNN digunakan sebagai model awal, sedangkan Improved CNN dibuat dengan arsitektur yang lebih kuat melalui penambahan BatchNormalization, convolution block yang lebih dalam, GlobalAveragePooling2D, dan custom class weight.

Hasil evaluasi menunjukkan bahwa Improved CNN jauh lebih baik dibandingkan Baseline CNN. Baseline CNN memperoleh test accuracy sebesar 54.74%, sedangkan Improved CNN memperoleh test accuracy sebesar 80.26%. Selain itu, recall meningkat dari 36.58% menjadi 73.16%, yang menunjukkan bahwa Improved CNN jauh lebih baik dalam mengenali data dari berbagai kelas.

Custom class weight untuk kelas glass juga memberikan pengaruh positif. Recall glass meningkat dari 0.33 pada Baseline CNN menjadi 0.74 pada Improved CNN. Hal ini menunjukkan bahwa model menjadi lebih mampu mengenali kelas glass setelah diberikan bobot tambahan.

Selain evaluasi numerik, model juga dianalisis menggunakan attention map visualization dengan Grad-CAM. Hasil Grad-CAM menunjukkan bahwa Improved CNN umumnya sudah mampu memperhatikan area objek utama pada beberapa prediksi yang benar. Namun, pada beberapa kasus kesalahan prediksi, model masih dapat terpengaruh oleh background, pencahayaan, atau objek yang kurang jelas. Dengan demikian, Grad-CAM membantu memberikan interpretasi visual terhadap keputusan model dan menunjukkan bagian yang masih perlu diperbaiki.

Secara keseluruhan, Improved CNN dipilih sebagai model terbaik pada project ini karena memberikan performa paling tinggi dan hasil evaluasi yang lebih seimbang antar kelas. Meskipun demikian, model masih dapat dikembangkan lebih lanjut menggunakan transfer learning, fine-tuning, penambahan data, focal loss, dan Grad-CAM visualization untuk interpretasi model.